Введение в машинное обучение

Лекция 7. Ранжирование

Осень 2025

Ранжирование

Ранжирование — процесс упорядочивания набора объектов в соответствии с некоторой мерой

Есть набор запросов {q1, q2,..., qm}

Есть набор документов {d1, d2,...,dn}

Нужно для каждого запроса подобрать и упорядочить документы

Как упорядочить?

Ранжирование

Трансформеры в Поиске: как Яндекс применил тяжёлые нейросети для поиска по смыслу

Постановка задачи

Мера релевантности — степень соответствия между запросом и документом (или набором документов).

Чем выше это соответствие, тем выше в списке ранжирования должен находиться документ.

$$\boxed{\text{Relevance}(\text{query}, \text{doc}) \sim \langle \text{Emb}^n(\text{query}), \text{Emb}^n(\text{doc}) \rangle}$$

Learning to rank

Задача (learning to rank – LTR) — создание глобальной модели $F(q, D)$, которая будет работать над всем корпусом документов.

Входные данные

Q – набор запросов $\{q1, q2, \dots, qm\}$

D – набор документов

Признаки:

- Признаки запроса (q): Длина запроса, категория, история пользователя.

- Признаки документа (d): PageRank, авторитетность источника, дата создания.

- Признаки запрос-документ (q, d): Степень совпадения запроса с текстом документа (TF-IDF, BM25), с заголовком, behavioral data (исторический CTR для этой пары).

Выход модели

-упорядоченный список документов по релевантности

-ранжирующая оценка

Целевая переменная – в обучающих данных заранее известно как должен выглядеть порядок документов - по релевантности, по попарным предпочтениям

Функция потерь

Функция разрабатывается для **оценки качества** порядка, а не точности предсказания -Pointwise; -Pairwise;- ListWise

Метрики качества

Качество/точность—*насколько аккуратна система ранжирования?*

Измеряем возможности системы ранжировать релевантные документы выше нерелевантных.

Эффективность—*насколько быстро выдается ответ? Какое количество ресурсов необходимо для формирования ответа?*

Измеряем затраты на память и время формирования ответа.

Удобство использования—*насколько полезна система для решения задач?*

Пользовательские ощущения, UX.

Оценка качества ранжирования

Зафиксированный набор документов;

Зафиксированный набор запросов;

Оценки релевантности пар (в идеале оценки даются пользователями системы);

Наборы должны быть репрезентативными.

DCG (Discounted cumulative gain)

Вычисляется по первым k документам из выдачи для запроса q

yi – истинный ответ для документа на i-ой позиции

Итоговая оценка усредняется по всем запросам

$$\mathrm{DCG@}k(q) = \sum_{i=1}^{k} \frac{2^{y_i} - 1}{\log(i+1)}$$

DCG (Discounted cumulative gain)

Выборка 1

$$DCG = \frac{2^1 - 1}{\log(2)} + \frac{2^0 - 1}{\log(3)} + \frac{2^0 - 1}{\log(4)} \approx 1.44$$

Выборка 2

$$DCG = \frac{2^0 - 1}{\log(2)} + \frac{2^1 - 1}{\log(3)} + \frac{2^0 - 1}{\log(4)} \approx 0.91$$

$$\mathrm{DCG@}k(q) = \sum_{i=1}^{k} \frac{2^{y_i} - 1}{\log(i+1)}$$

Методы ранжирования

- Pointwise
- Pairwise
- Listwise

Pointwise

Модель *a(q,d)* обучается для предсказания ответов yi, но не содержит ***порядок***

Например – регрессия

$$\sum_{(q,d,y)\in R} (\langle w, x(q,d)\rangle - y_i)^2 \to \min_w$$

x(q,d) – признаки для пары «запрос-документ»

Дает точные значения, НО нас интересует *порядок*

Pairwise

$o_i \equiv f(x_i)$ — предсказание нашего алгоритма для одного объекта (*логит* или *скор*)

$o_{ij} \equiv f(x_i) - f(x_j)$ - сходство порядка в ранжировании

$P_{ij} = \frac{e^{o_{ij}}}{1+e^{o_{ij}}}$ — функция отображения предсказания (логита) в вероятность.

Тогда функция потерь

$$C_{ij} = -\overline{P}_{ij} o_{ij} + \log(1 + e^{o_{ij}})$$

Pij — предсказание модели; $\overline{Pij}$ — целевая метка (*таргет*)

Learning to Rank using Gradient Descent

Listwise

Ключевая идея: Работать сразу со всем списком документов для одного запроса. Модель пытается предсказать оптимальную перестановку документов в этом списке, **напрямую оптимизируя метрики качества ранжирования**

1) На вход модели подается весь список документов для конкретного запроса q: $L = [d_1, d_2, \ldots, d_n]$.

2) Для каждого документа в списке вычисляется его ранжирующий скор с помощью модели F(x).

3) Функция потерь (Loss Function) сравнивает два распределения вероятностей:

- Распределение, полученное из предсказанных моделью оценок.
- Распределение, полученное из истинных оценок релевантности.

4) Модель обучается так, чтобы эти два распределения были как можно более похожими

Learning to Rank: From Pairwise Approach to Listwise Approach

Ранжирование – многоступенчатый процесс

Сначала – сначала простейшие алгоритмы,

а на ограниченной выборке – самые точные