Введение в машинное обучение

Лекция 8. Кластеризация

Осень 2025

Кластеризация

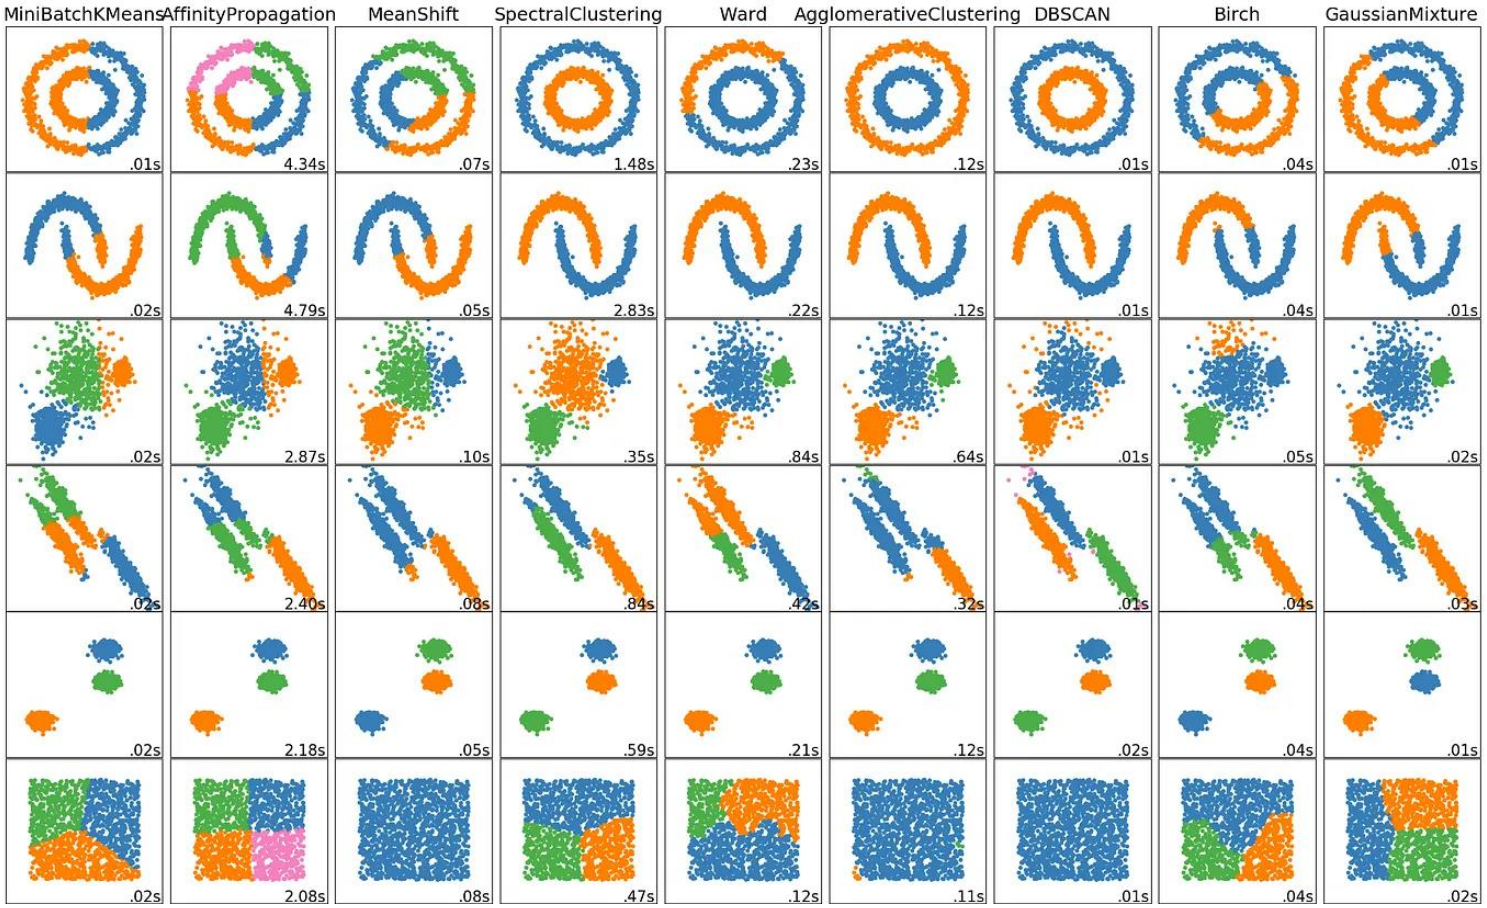

Отличия от обучения с учителем

- нет строгой постановки задачи (против минимизации функционала ошибки)
- количество кластеров (как правило) не известно
- нет правильных ответов

Агломеративная иерархическая кластеризация

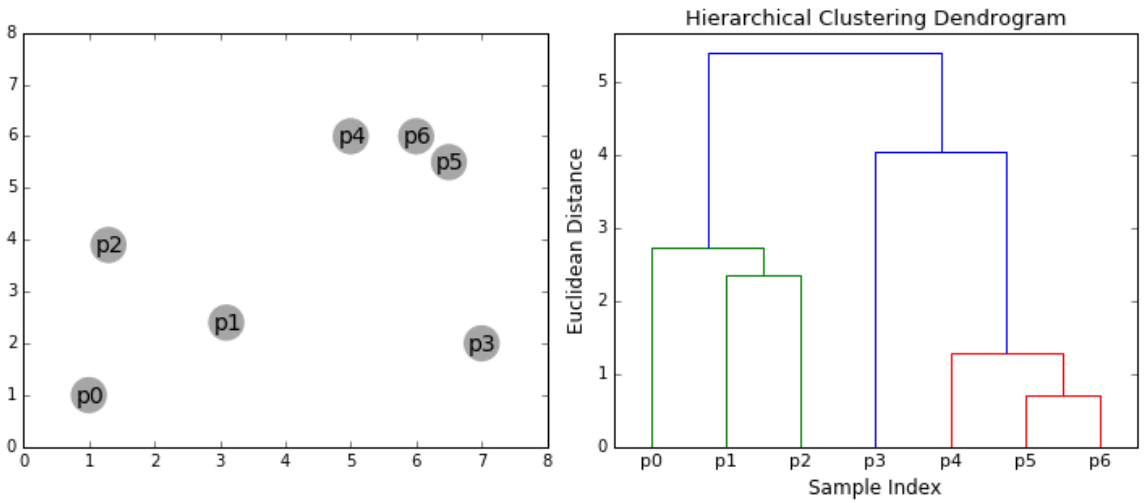

Агломеративные методы начинают кластеризацию с небольших кластеров, и далее растут размеров побольше.
Дивизивные методы первоначально дают большие кластеры и далее делят их на более мелкие.

Меры расстояний между объектами

Пусть x и x' будут двумя объектами из вселенной возможных объектов. Расстояние (подобие) между x и x' - это вещественное число, обозначаемое sim(x, x').

Евклидова мера:

$$sim(x, x') = x^\top x'$$

Косинусное расстояние:

$$\begin{aligned} sim(x, x') &= \cos(\theta) \\ &= \frac{x^\top x'}{\|x\| \cdot \|x'\|} \\ &= \frac{x^\top x'}{\sqrt{x^\top x}\sqrt{x'^\top x'}}. \end{aligned}$$

Применяются и другие меры:
- манхеттенское, Минковского и тд

Меры расстояний между кластерами

Single Link

- $d(C_i, C_j) = \min_{x \in C_i, x' \in C_j} d(x, x')$. This is known as *single-linkage*. It is equivalent to the minimum spanning tree algorithm. One can set a threshold and stop clustering once the distance between clusters is above the threshold. Single-linkage tends to produce long and skinny clusters.

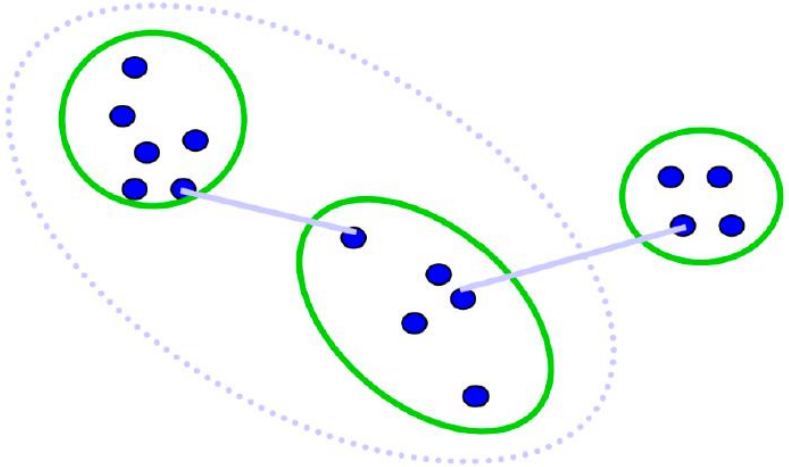

Длинные, тощие кластеры

Меры расстояний между кластерами

Complete Link

- $d(C_i, C_j) = \max_{x \in C_i, x' \in C_j} d(x, x')$. This is known as *complete-linkage*. Clusters tend to be compact and roughly equal in diameter.

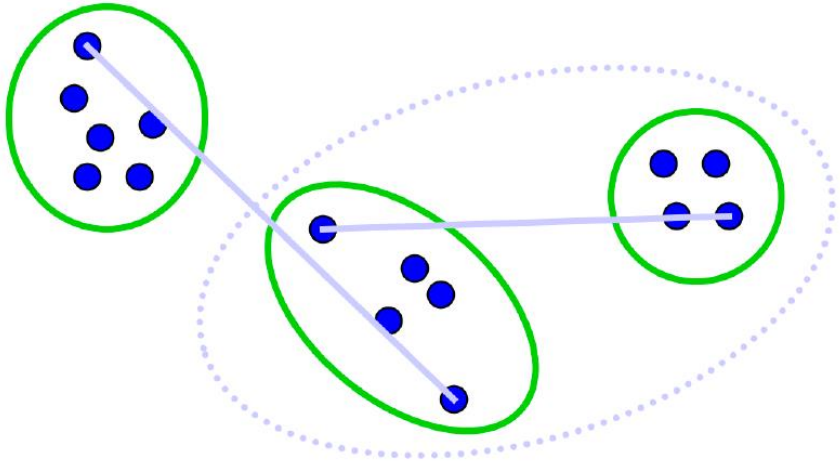

Тесные кластеры

Меры расстояний между кластерами

Average Link

- $d(C_i, C_j) = \frac{\sum x \in C_i, x' \in C_j d(x,x')}{|C_i| \cdot |C_j|}$. This is the average distance between items. Somewhere between single-linkage and complete-linkage.

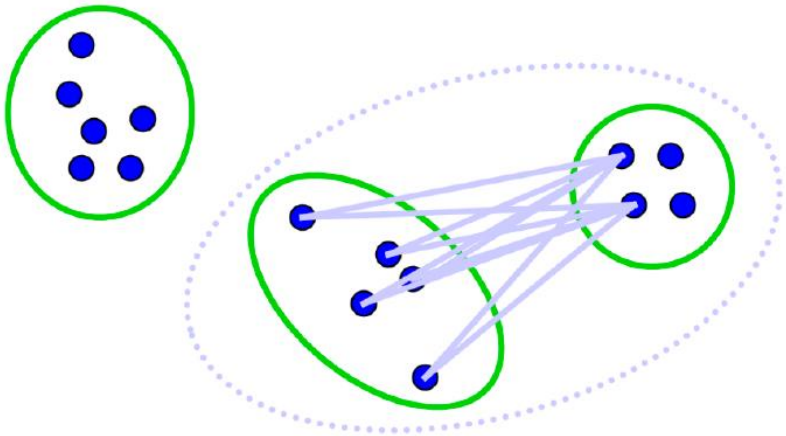

Устойчивость к шуму

Меры расстояний между кластерами

- **Single Linkage**

  $D(c_1,c_2) = \min D(x_1,x_2)$

  Minimum distance or distance between closest elements in clusters

- **Complete Linkage**

  $D(c_1,c_2) = \max D(x_1,x_2)$

  Maximum distance between elements in clusters

- **Average Linkage**

  $D(c_1,c_2) = \frac{1}{|c_1|}\frac{1}{|c_2|}\Sigma\Sigma D(x_1,x_2)$

  Average of the distances of all pairs

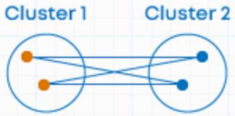

- **Centroid Method**

  Combining clusters with minimum distance between the centroids of the two clusters

- **Ward's Method**
  - Combining clusters where increase in within cluster variance is to the smallest degree.

  - Objective is to minimize the total within cluster vairance

Мера остановки

- количество кластеров
- рост расстояния по отношению к прошлой итерации и др.

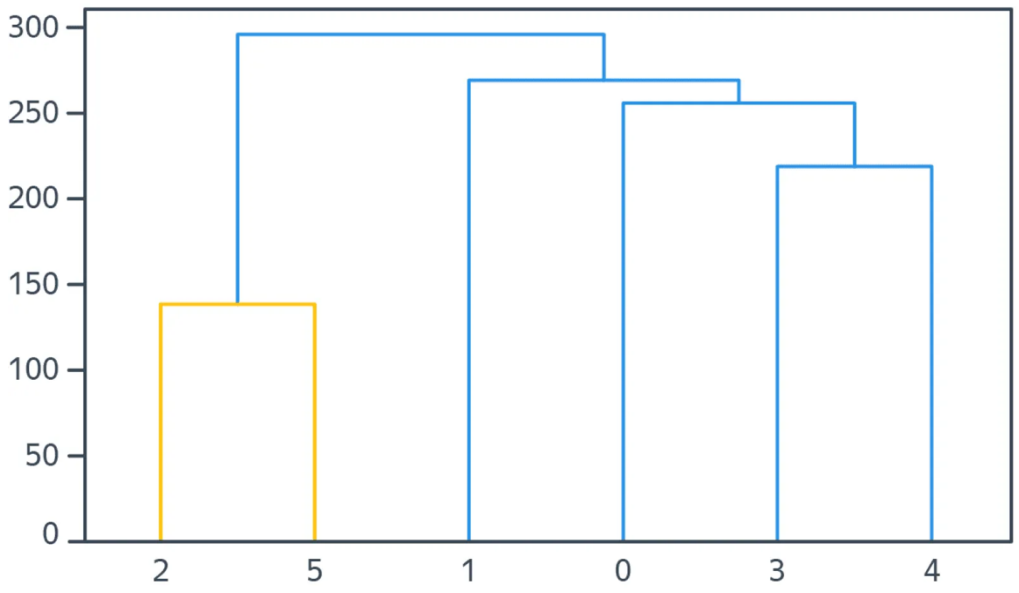

K-means

1) задается число кластеров изначально
2) случайно выбираются центры кластеров
3) итеративный проход по объектам:
   - отнести каждый объект к ближайшему центру
   - переместить центр каждого кластера в центр тяжести новой формы кластера

Внутрикластерное расстояние может использоваться как метод выбора количества кластеров

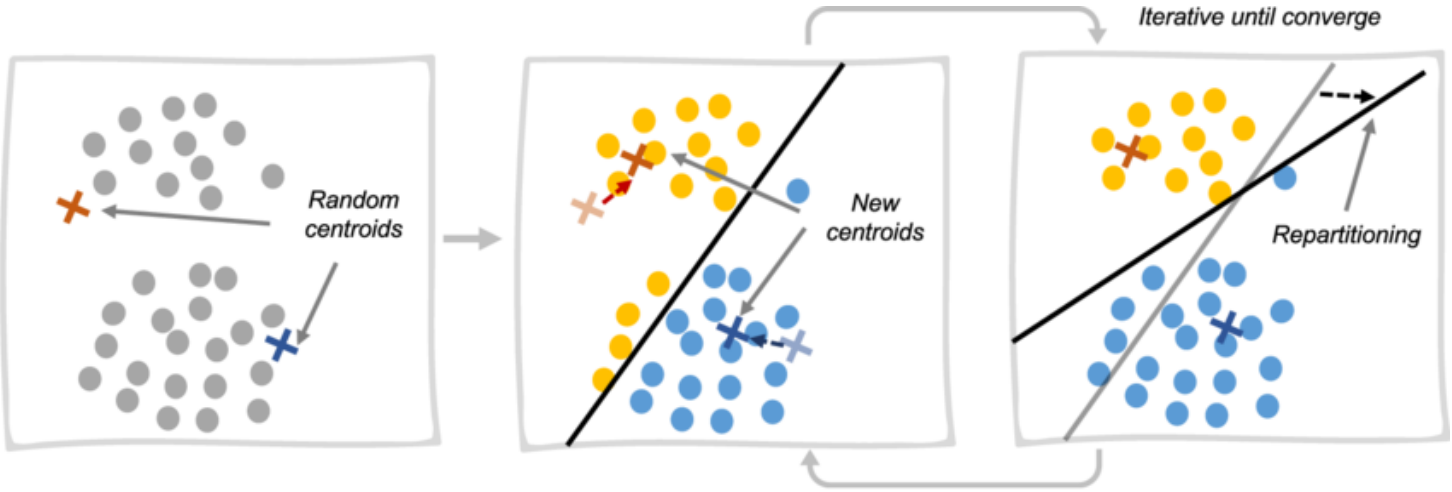

Input: distance matrix *D* & number of clusters *k*

Mean-shift

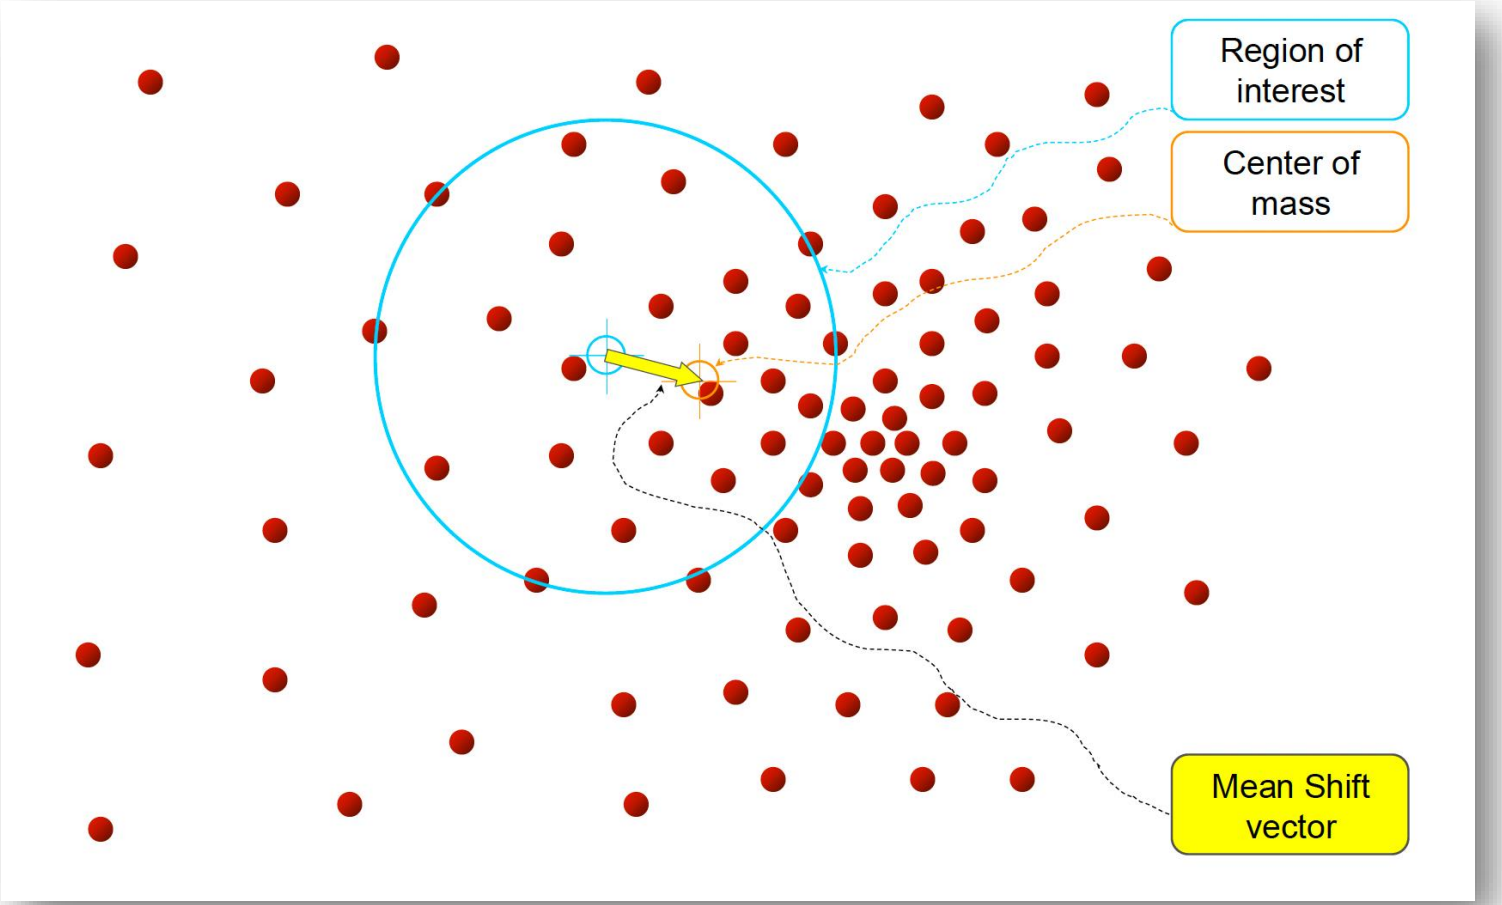

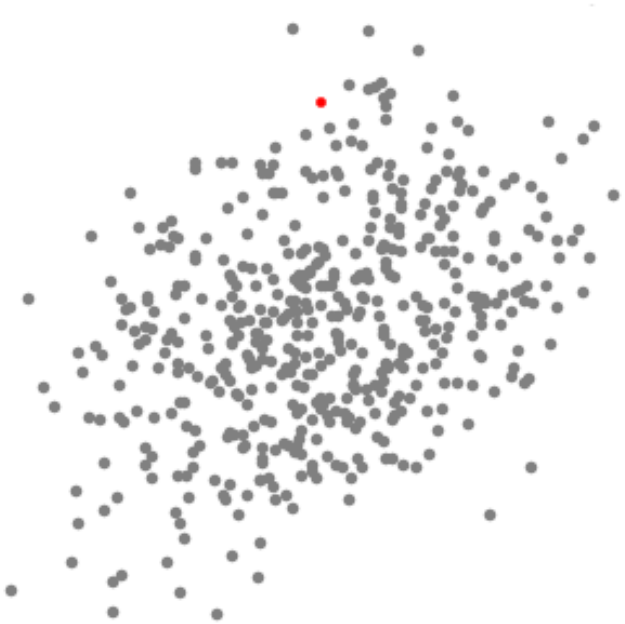

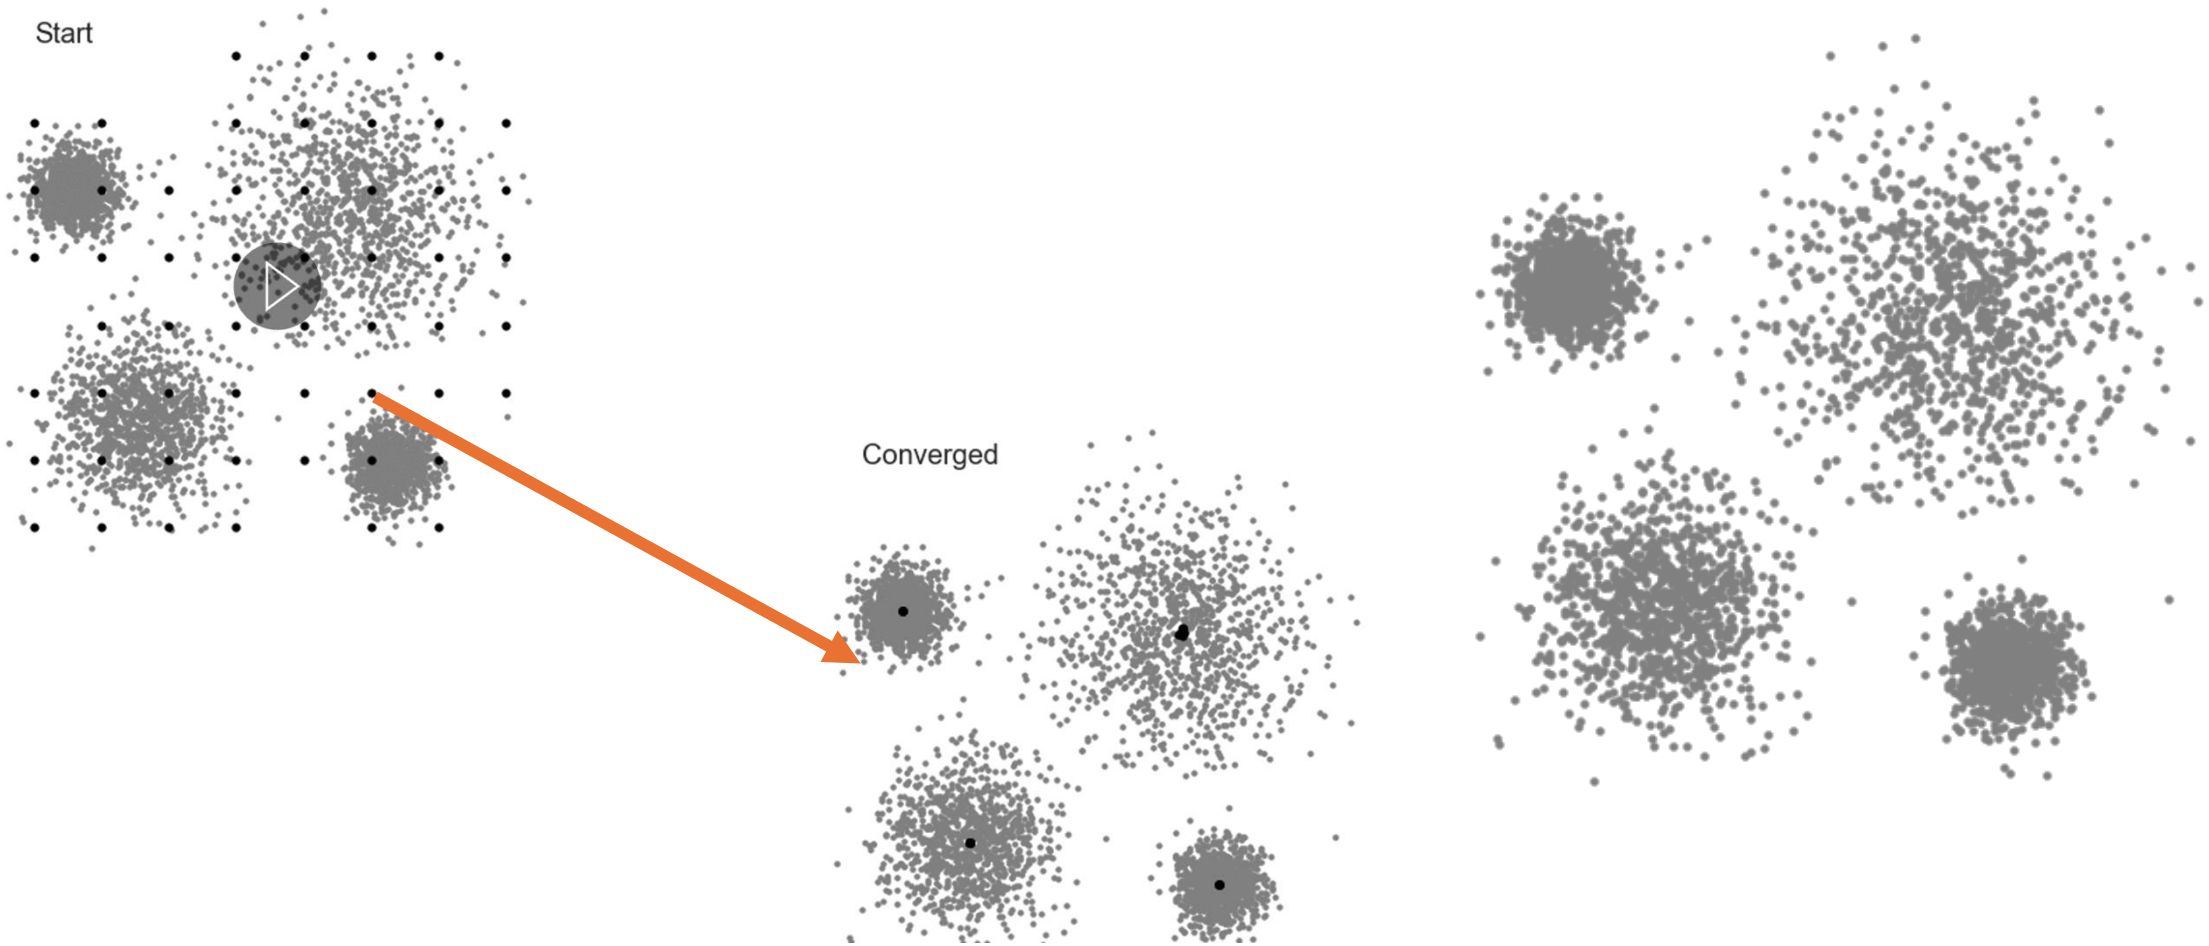
Start
Converged

Итоги Mean-shift

- применяется с разными ядерными функциями
- не требует изначальной инициализации кластеров
- только один параметр – размер окна (bandwidth)
- не требует задания числа кластеров
- устойчив к форме кластеров

Применение: кластеризация, трекинг объектов, фильтры (размытие)

DBSCAN

Density-Based Spatial Clustering of Applications with Noise

Параметры:

- размер окрестности
- мин количество объектов окрестности

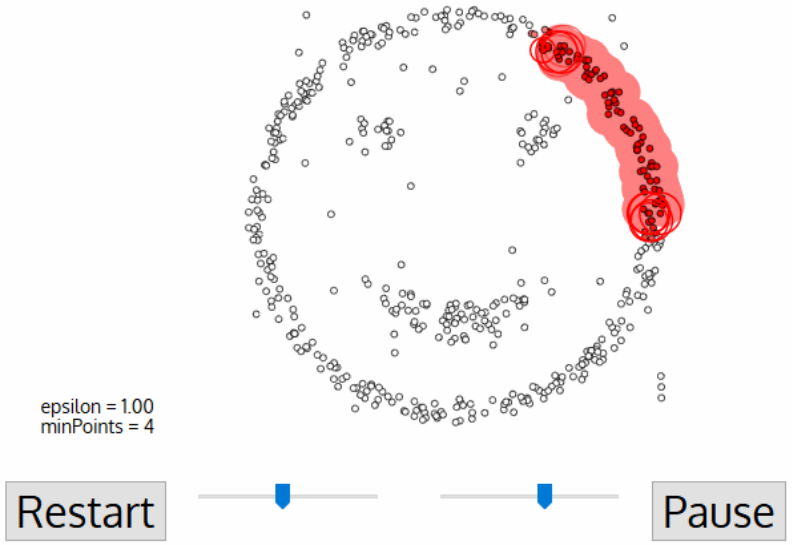

- epsilon 32
- samples 5

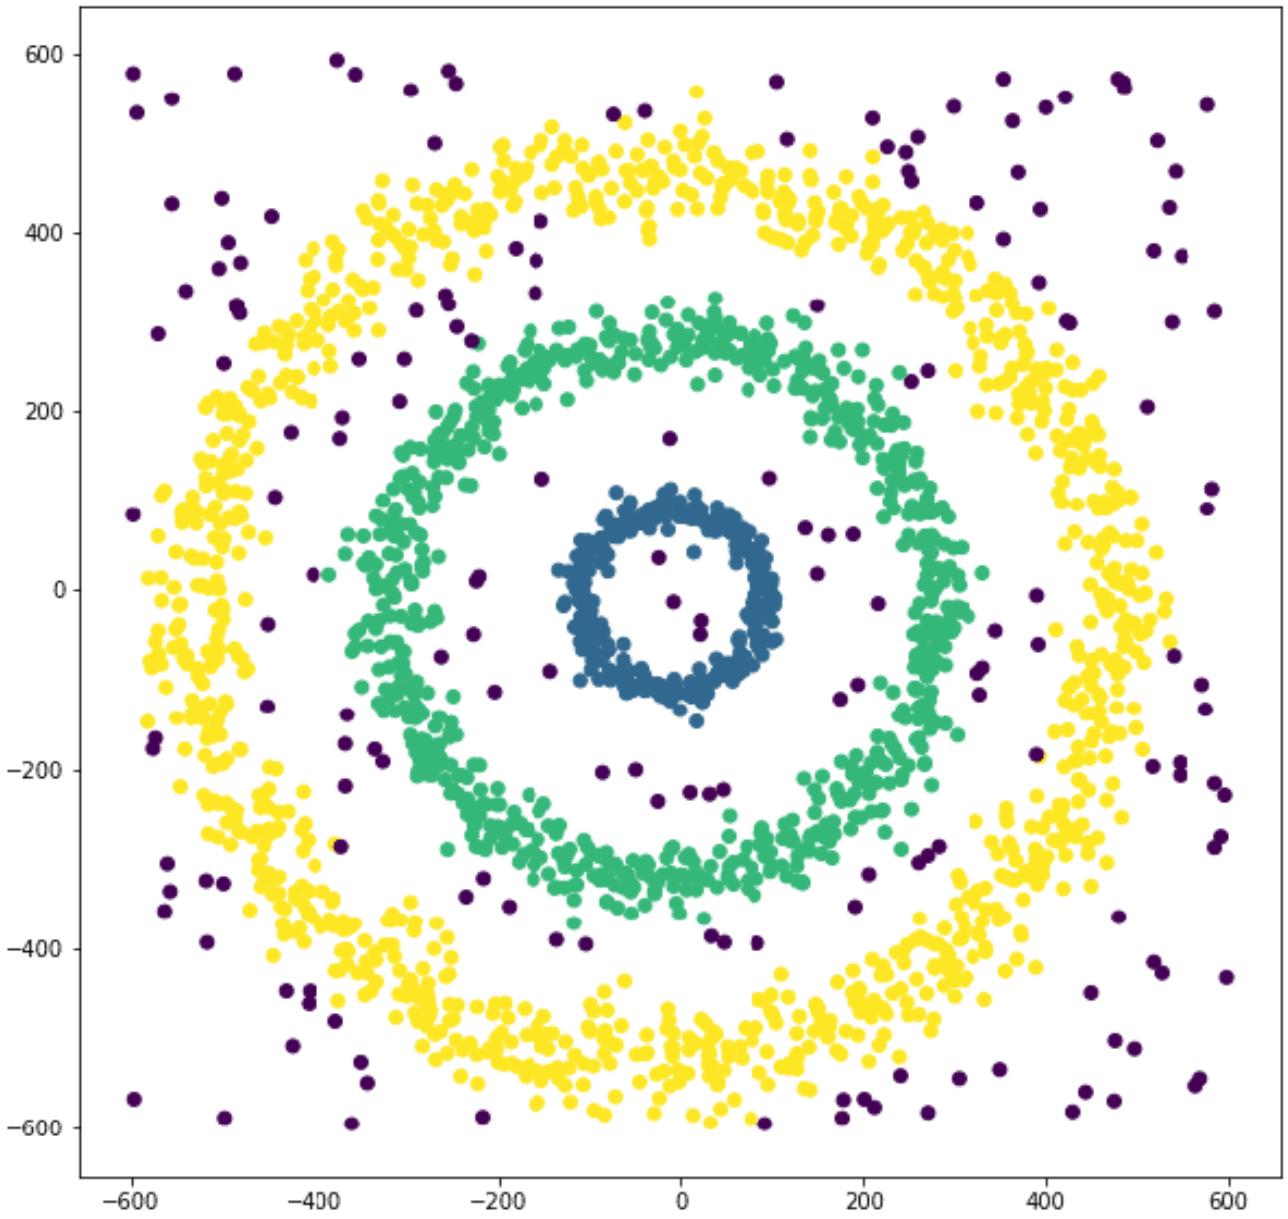

Ссылки

- Применение mean-shift при трекинге
- Интерактивное приложение по кластеризации
- Scikit clustering
- Top 5 clustering algo